

FUNDAÇÃO GETULIO VARGAS
ESCOLA DE MATEMÁTICA APLICADA

DANILO LEMOS CARDOSO

SÍNTESE DE TEXTURAS BASEADO EM EXEMPLO: SUBTITULO

Rio de Janeiro
2022

DANILO LEMOS CARDOSO

SÍNTESE DE TEXTURAS BASEADO EM EXEMPLO

Trabalho de conclusão de curso apresentada para a Escola de Matemática Aplicada (FGV/EMAp) como requisito para o grau de bacharel em Matemática Aplicada.

Área de estudo: area de estudo.

Orientador: Asla Medeiros e Sá

Rio de Janeiro

2022

Ficha catalográfica elaborada pela BMHS/FGV

Sobrenome, Nome

Síntese de Texturas Baseado em Exemplo: subtítulo/ Danilo Lemos Cardoso. – 2022.

14f.

Trabalho de Conclusão de Curso – Escola de Matemática Aplicada.

Advisor: Asla Medeiros e Sá.

Includes bibliography.

1. Matemática 2. Aplicada 2. na matemática I. Sobrenome professor, Nome professor II. Escola de Matemática Aplicada III. Síntese de Texturas Baseado em Exemplo

DANILO LEMOS CARDOSO

SÍNTESE DE TEXTURAS BASEADO EM EXEMPLO: SUBTITULO

Trabalho de conclusão de curso apresentada para a Escola de Matemática Aplicada (FGV/EMAp) como requisito para o grau de bacharel em Matemática Aplicada.

Área de estudo: area de estudo.

E aprovado em 21/12/2021
Pela comissão organizadora

Asla Medeiros e Sá
Escola de Matemática Aplicada

Convidado 1
Instituição 1

Convidado 2
Instituição 2

Resumo

Temas relacionados à análise e síntese de imagens vêm tendo um crescente aumento de interesse nos últimos anos, tanto por parte de pesquisadores, quanto pelo público geral. Isso se deve ao aumento do poder computacional e da geração de dados, que possibilitam o estudo e desenvolvimento de modelos mais ricos e com melhores resultados.

Neste trabalho será tratado da geração de texturas de tamanho arbitrário usando uma amostra limitada, tentando assim modelar seu processo de geração para produzir um resultado perceptualmente semelhante ao original. Será feita uma revisão da literatura sobre o tema, mostrando os principais resultados e abordagens, como a área foi se desenvolvendo até chegar no conhecimento de hoje, e como esse área influenciou em outros temas relacionados a imagem.

No final será mostrada uma implementação do método computacional de geração de texturas, aplicando-o em diferentes tipos de textura para observar como características da imagem original podem mudar a qualidade do resultado. Em seguida serão exploradas variações do método que permitem um melhor controle da forma do resultado final.

Palavras-chave: síntese de textura.

Sumário

1	INTRODUÇÃO	6
1.1	O que é textura	6
1.2	O que é síntese de textura	6
2	MODELOS	8
2.1	Modelos paramétricos	8
2.2	Modelos não paramétricos	8
2.3	Modelos de aprendizado profundo	9
3	DEEP LEARNING	10
3.1	Aprendizado de Representação	10
3.2	Redes neurais	10
3.3	Redes convolucionais	11
3.4	Síntese de textura com Redes Convolucionais	11
4	VARIAÇÕES	12
4.1	Analogias de Texturas	12
4.2	Transferência de estilo	12
5	RESULTADOS	13
6	CONCLUSÃO	14
6.1	Perspectivas	14

1 Introdução

...

O trabalho foi baseado em dois Surveys na área. O primeiro de Wei, Lefebvre, Kwatra e Turk (**Wei2009**) dá ênfase em abordagens não paramétricas e texturas dinâmicas. Já o segundo de Raad, Davy, Desolneux e Morel (**Raad2018**) mostra a síntese com métodos mais recentes usando Deep Learning e Redes Convolucionais. Analisando os dois Surveys, fica bem claro o quanto a área se modificou depois da revolução do Deep Learning, que se iniciou em 2015 com o trabalho de Yann LeCun, Yoshua Bengio e Geoffrey Hinton (**LeCun2015**).

1.1 O que é textura

A palavra “textura” pode ter diferentes significados dependendo do contexto. Um deles se refere às diferentes características da superfície de um objeto, sejam elas visuais (cor, desenhos), geométricas (relevo, forma) ou táteis (maciez, dureza). Em computação gráfica, textura geralmente é o nome que se dá a uma imagem (matriz de pixels) que descreve alguma característica da superfície de um objeto, como a cor ou a direção do vetor normal (utilizada para iluminação).

Para o processo de síntese, é preciso restringir o conjunto de imagens consideradas texturas àquelas que apresentam algum tipo de padrão perceptual em seu domínio. Com isso é possível fazer a síntese estudando e imitando o processo que gerou esse padrão.

Cross, G.R. e Jain, A.K. (**Cross1983**) descrevem textura como sendo um Campo Markoviano Aleatório (Markov Random Field, MRF). Esse modelo é o mais usado no processo de síntese pois satisfaz a propriedade de Markov (o valor de cada pixel dado sua vizinhança não depende do resto da textura) e a homogeneidade (a distribuição é invariante por translação), logo se encaixa com as necessidades descritas anteriormente.

1.2 O que é síntese de textura

O processo de síntese de textura baseado em amostra não tem uma definição clara matematicamente, é algo mais intrínseco à percepção humana. O objetivo é, a partir de uma amostra de textura, gerar outras texturas de tamanho arbitrário que imitam o processo gerador da amostra. Esse processo gerador é baseado em métricas perceptuais, que não podem ser definidas de forma fechada, pois podem depender de aspectos finos da imagem, como forma e iluminação. Assim, os trabalhos na área nos últimos anos consistem

em tentar descobrir melhores aproximações para essa métrica perceptual.

Ao restringir o conjunto de imagens aos Campos Markovianos, o processo de síntese pode ser descrito como uma re-amostragem da distribuição condicional da amostra. Com isso, o desafio do método passa a ser descobrir a distribuição a partir da amostra.

2 Modelos

2.1 Modelos paramétricos

Os modelos que fazem a síntese a partir de um conjunto de estatísticas da amostra original são chamados modelos paramétricos. Esses modelos partem de um ruído e fazem a síntese reduzindo a diferença entre as estatísticas desse ruído e da amostra utilizando uma função de otimização. A qualidade do modelo vai depender do conjunto de estatísticas escolhido e do tipo de otimização utilizado.

...

2.2 Modelos não paramétricos

Diferentemente dos modelos paramétricos, os modelos não paramétricos não dependem do cálculo de alguma estatística da amostra original para o processo de síntese. Ele gera a imagem pegando informação diretamente da amostra de modo a simular a amostragem da textura.

Essa forma de amostragem foi proposta inicialmente por Efros e Leung (**Efros1999**). Ela consistia em re-amostrar a textura pixel por pixel, pegando diretamente da imagem original o pixel que tem a vizinhança mais parecida com a vizinhança de seu destino. Os resultados na época foram bem superiores aos que se podiam obter com os métodos paramétricos, mas a procura por todas as vizinhanças na amostra tornava o método lento.

Mais tarde, Efros e Freeman (**Efros2001**) propuseram o método de Quilting (costura), que fazia a amostragem a partir de pedaços da imagem original. O método consistia em selecionar janelas de tamanho fixo da amostra e distribuí-las com uma sobreposição sobre elas. Em seguida é usado um algoritmo de min-cut para dividir essas janelas em pedaços que se encaixam para formar a nova textura. Essa abordagem era mais rápida computacionalmente do que o método anterior, e produzia resultados tão bons quanto.

Com os avanços na área, Vivek Kwatra (**Kwatra2005**) propôs uma amostragem fazendo a minimização do que ele define como função de energia. Essa função é a diferença quadrática entre as vizinhanças da textura gerada e as vizinhanças mais próximas de cada uma. O método usa uma variação do algoritmo EM, onde na fase “E” a energia é diminuída por mínimos quadrados, e na fase “M” a energia é diminuída escolhendo as vizinhanças mais próximas na amostra.

2.3 Modelos de aprendizaje profundo

3 Deep Learning

Um dos principais problemas na área de classificação de imagens era o reconhecimento de dígitos escritos à mão. Essa dificuldade vinha pela grande variação de forma e posição dos números, tornando os modelos muito complexos e pouco precisos. O desenvolvimento recente na área de Machine learning permitiu a criação de modelos simples capazes de aprender com os dados e fazer generalizações precisas, em alguns casos superando a percepção humana.

Neste capítulo serão apresentadas técnicas que usam Redes Neurais, como elas foram desenvolvendo ao longo dos anos, e como podemos aplicá-las na Síntese de Textura.

3.1 Aprendizado de Representação

Para um problema de classificação de imagens, é preciso saber quais são as informações úteis de extrair para obter uma melhor representação de seu conteúdo. Uma representação boa pode esconder informações redundantes ou realçar fatores que melhor explicam a imagem. Bengio, Courville e Vincent (**Bengio2014**) falam do importante papel que a aprendizagem de representações tem em Machine Learning. Um algoritmo que aprendesse tais representações eliminaria o trabalho de desenvolvê-las, o que tornaria mais rápido a criação de aplicações.

3.2 Redes neurais

Redes Neurais são um tipo de modelo de Machine Learning inspirado em redes de neurônios naturais e como eles se comunicam. Elas podem ser representadas por um grafo, onde cada nó representa um valor e cada aresta representa uma dependência. Essas redes podem ter vários formatos dependendo do tipo de aplicação.

Um exemplo comum de Rede Neural é o Multi Layer Perceptron. Nesse modelo, a rede é dividida em camadas de diferentes tamanhos, e o dado flui da camada de entrada até a saída, que pode representar uma classificação da entrada ou uma função geral.

Cada camada da rede tem como parâmetros os offsets \mathbf{b}_m e uma matriz de pesos $\mathbf{W}_{m \times n}$. Assim, a transformação da entrada \mathbf{x}_n na saída \mathbf{y}_m pode ser representada com a seguinte operação:

$$\mathbf{y} = \varphi(\mathbf{W}\mathbf{x} + \mathbf{b}), \quad (3.1)$$

onde φ é uma função não linear, comumente chamada de “função de ativação”.

Os parâmetros são calculados minimizando uma função de erro na saída. Esse cálculo é feito calculando o gradiente dos parâmetros em relação à função de perda. Como a derivada de todas as funções aplicadas é conhecida, o gradiente pode ser calculado computacionalmente usando “backpropagation”.

Esse modelo é útil por envolver operações bem simples e rápidas de serem calculadas computacionalmente. Cada camada distorce o espaço de entrada para torná-lo linearmente separável no final. Pela sua flexibilidade, o modelo geralmente é chamado de aproximador universal de qualquer função, pela sua capacidade de aprender funções complexas a partir de algumas amostras.

...

3.3 Redes convolucionais

O Multi Layer Perceptron, quando aplicado diretamente nos pixels de uma imagem aparecem dois problemas consideráveis: a quantidade de parâmetros cresce muito, e informações espaciais da imagem são perdidas. Geralmente um objeto que queremos identificar pode aparecer em diferentes posições da imagem, ao transformá-la em um vetor perdemos essa invariância por translação. Com base nisso se tornou necessário desenvolver uma rede que faz representações independentes de translações e que tenham poucos parâmetros.

A operação de convolução

3.4 Síntese de textura com Redes Convolucionais

4 Variações

O trabalho de síntese de textura não fica limitado apenas a re-amostrar a imagem de entrada. Ao longo dos

4.1 Analogias de Texturas

(Hertzmann2001)

4.2 Transferência de estilo

O método de “Style Transfer” proposto por Gatys, Ecker e Bethge (**Gatys2016**) nos permite, além de re-amostrar a textura, controlar a geometria do resultado. Para isso o algoritmo recebe duas imagens, uma definirá o estilo e outra definirá o conteúdo do resultado.

...

5 Resultados

6 Conclusão

6.1 Perspectivas

"